

Optimización de la generación de una red eléctrica

Iñaki Diez Lambies

MUIARFID Curso 2023 – 2024
Asignatura de Técnicas de Inteligencia
Artificial

TABLA DE CONTENIDO

1.	Introducción.....	3
2.	Descripción del problema	4
2.1.	Modelización.....	4
2.2.	Funciones objetivo.....	5
2.2.1.	Minimizar el coste desperdiciado	5
2.2.2.	Maximizar el uso de energías renovables	5
2.3.	Parámetros escogidos.....	6
3.	Algoritmo genético	8
3.1.	Codificación.....	8
3.1.1.	Reparación	8
3.2.	Pasos del algoritmo.....	9
3.2.1.	Selección	9
3.2.2.	Cruce	9
3.2.3.	Mutación	9
3.2.4.	Reemplazo.....	10
3.3.	Condición de parada	10
3.4.	Parámetros.....	10
4.	Enfriamiento simulado	12
4.1.	Codificación.....	12
4.2.	Pasos	12
4.2.1.	Solución inicial.....	12
4.2.2.	Elección de vecinos	13
4.3.	Condición de parada	13
4.4.	Parámetros.....	13
5.	Implementación.....	15
5.1.	Modelo.....	15
5.1.1.	Clase generador	15
5.1.2.	Clase individuo	15
5.1.3.	Clase población	15
5.2.	Experimentación	15
5.2.1.	Clase runner	15
5.2.2.	Clase visualizador	15
6.	Evaluación de los resultados.....	16
6.1.	Algoritmo genético	16
6.2.	Enfriamiento simulado.....	18

7.	Conclusiones	21
7.1.	Implicaciones y futuras Líneas de Investigación	21

1. INTRODUCCIÓN

El presente trabajo se adentra en el análisis comparativo de dos métodos de optimización altamente reconocidos en el campo de la inteligencia artificial y la computación: el algoritmo genético y el enfriamiento simulado. Ambos enfoques, aunque distintos en su naturaleza y mecanismos de funcionamiento, han demostrado ser herramientas poderosas para abordar problemas complejos de optimización en diversas áreas. En esta ocasión, nos centraremos en su aplicación para resolver un problema específico relacionado con la distribución y optimización de cargas en una red eléctrica.

El problema en cuestión simula el balanceo de cargas de múltiples generadores que suministran energía a una única ciudad, representando así un escenario realista en el cual la gestión eficiente de los recursos energéticos es crucial. La complejidad del problema se ve aumentada por la introducción de diversas variables y condiciones que buscan emular las dinámicas y restricciones típicas de las redes eléctricas.

Para abordar este problema, se han definido dos funciones objetivo: minimizar el coste desperdiciado y maximizar el uso de energías renovables. Estos objetivos reflejan la dualidad existente entre la eficiencia económica y la responsabilidad medioambiental, dos aspectos críticos en la gestión de recursos energéticos en la actualidad. A lo largo de este trabajo, se busca no solo comparar la efectividad de los algoritmos genéticos y el enfriamiento simulado para alcanzar estos objetivos, sino también entender cómo cada método se adapta y responde a las particularidades del problema.

Para proporcionar un marco robusto y representativo de la realidad, se han seleccionado cuidadosamente los parámetros del modelo del problema, optando por un enfoque de selección parcialmente aleatoria para asegurar la generalidad y aplicabilidad de los resultados obtenidos. Esta decisión refleja el reconocimiento de la naturaleza impredecible de los problemas de optimización en el mundo real y fortalece la validez de las conclusiones derivadas de este estudio.

El documento está estructurado de manera que permite al lector seguir de cerca el desarrollo del análisis, comenzando con una descripción detallada del problema y su modelización, seguido por la presentación de los algoritmos en cuestión, su implementación, y finalmente, la evaluación de los resultados obtenidos. Además, se exploran posibles ampliaciones y se concluye con reflexiones finales que buscan consolidar los aprendizajes obtenidos y proporcionar una perspectiva clara sobre la utilidad y aplicabilidad de los métodos de optimización estudiados en el contexto de las redes eléctricas y la gestión de recursos energéticos.

En resumidas cuentas, este trabajo no solo aporta al entendimiento comparativo de los algoritmos genéticos y el enfriamiento simulado en un contexto aplicado, sino que también contribuye a la discusión más amplia sobre cómo las técnicas de optimización pueden ser herramientas clave en la transición hacia sistemas energéticos más eficientes y sostenibles.

2. DESCRIPCIÓN DEL PROBLEMA

El problema intenta simular un proceso de optimización y balance de cargas de múltiples generadores hacia un único consumidor. En nuestro caso, nos encontramos ante una red eléctrica donde múltiples generadores deben dar energía a una única ciudad, podemos apreciar una representación en la Ilustración 1.

Para intentar simular una situación más realista se han propuesto distintas variables y condiciones que, además de esto, añaden una complejidad al problema que se ha considerado interesante para el estudio.




Ilustración 1 - Esquema representativo del problema

2.1. MODELIZACIÓN

En primer lugar, nos encontramos con que el consumidor (la ciudad) tiene un determinado número de tramos horarios. Para cada tramo horario tiene una cierta demanda (expresada en kilovatios) que debe ser suplida por la suma de los generadores.

Los tramos horarios son aquellas divisiones que se puedan realizar de un cierto horario. En nuestro caso nos podemos imaginar que el problema intenta solucionar un día en el calendario y que ese día trata de dividirse en ciertas partes, si fueran dos hablaríamos de tramos de doce horas mientras que si fueran tres hablaríamos de tramos de ocho horas.

Es por ello por lo que todos los generadores deben colaborar para, en cada tramo horario suplir la energía necesaria. Las variables que definen a los generadores, por tanto, son las siguientes:

- **Generación máxima por tramo:** número de kilovatios máximo que puede suplir el generador al consumidor, existe uno por cada tramo.
- **Porcentaje de uso del generador por tramo:** nos indica cuanta de esa generación máxima se está actualmente generando, tenemos un valor por cada tramo. Este valor multiplicado por la generación máxima nos permite tener el número de kilovatios que se están generando por cada tramo.
- **Coste variable por tramo:** coste de cada kilovatio, tenemos un precio distinto para cada tramo.
- **Coste fijo por tramo:** precio fijo que se aplica al coste de la energía generada si el porcentaje de uso es mayor que cero en ese tramo.

- **Número de tramos de descanso:** valor que indica el número de tramos en los que un generador debe descansar, es decir, tener un porcentaje de uso igual a cero.

Todas estas variables intentan simular una situación cercana a la realidad. Por ejemplo, que cada tramo tenga unas variables diferentes (generación máxima, coste variable y coste fijo) intenta modelar de alguna forma un caso real donde todas estas variables son dependientes de los tramos horarios de un día a nivel productivo (se imagina por ejemplo una planta solar donde depende de a qué hora el sol puede llegar a generar cierta cantidad de energía) o a nivel de costes (los trabajadores presentan costes fijos por ir a trabajar).

2.2. FUNCIONES OBJETIVO

Gracias a la complejidad del problema se nos presentan múltiples posibles funciones objetivo que se podrían intentar optimizar para el problema. En el caso que atañe a este trabajo se ha planteado la idea de intentar perseguir la optimización simultánea de dos objetivos que, como veremos más adelante, tienen claramente intereses encontrados.

2.2.1. MINIMIZAR EL COSTE DESPERDICIAO

Teniendo en cuenta cuestiones tanto económicas como ambientales, puede ser de interés intentar minimizar aquellos costes innecesarios para una red eléctrica. Se entienden los costes como aquello que no forma parte de la productiva del sistema, en nuestro caso, aquella energía generada que bien sobra (que es mayor que la demanda) o que bien falta (porque podría haberse utilizado por el consumidor para una actividad productiva). Esto se aplicará para cada tramo.

En cada uno de estos tramos nos encontramos con que para cada generador se realizará el cálculo de la energía que está generando. Posteriormente, ordenaremos todos los generados del más barato al más caro en cuanto a generación variable (para beneficiar al consumidor) e iremos restando la energía generada de estos de la demandada por el consumidor. Si no se ha suplido la energía, aquella demanda restante se convertirá en el coste (multiplicando los kilovatios faltantes al coste del generador más caro que haya generado energía en ese tramo). Si ha sobrado energía después de suplir la demanda, toda la energía sobrante será convertida en coste del generador más caro que haya generado en ese tramo (al igual que en el caso anterior).

Con esta forma de calcular el coste se buscan dos cosas. La primera es que se penalice tanto la falta de demanda suplida como la sobrante, intentando que el problema converja en un punto donde el valor de coste variable se acerque a cero, es decir, se suple la demanda sin energía sobrante. En segundo lugar, al utilizar el coste del generador más caro empleado, conseguimos intentar que sean generados con bajo coste variable los que intente suplir la demanda la mayoría de las veces.

En último lugar, al coste desperdiciado se suman también los costes fijos de aquellos generadores que hayan generado para ese tramo.

2.2.2. MAXIMIZAR EL USO DE ENERGÍAS RENOVABLES

En el contexto socioeconómico actual, se hace impensable no tener en cuenta las consecuencias medioambientales de cualquier actividad productiva y es por ello por lo que se entiende la utilidad de este objetivo.

De la misma forma que el anterior objetivo, para cada tramo se calculará la energía utilizada para suplir la demanda (de la más barata a la más cara). De esta energía efectiva (utilizada para suplir la demanda)

se extraerá aquella que sea generada por energías renovables y la suma de esta será la que utilicemos como medida (expresada en kilovatios).

2.3. PARÁMETROS ESCOGIDOS

Como se ha podido ver hasta ahora, nos encontramos ante un problema complejo que requiere multitud de factores y que, por tanto, el árbol de soluciones que se podrían generar es verdaderamente amplio y variado.

Además, para encontrar un *trade-off* entre ambas funciones objetivo se han considerado que las fuentes de energía renovable sean de base más ineficientes (en cuanto a coste fijo y máxima generación posible) que aquellas de energías no renovables. De esta forma la idea es que las soluciones tengan que decidir entre tener un bajo coste sobrante o una alta generación de energías renovables, pero nunca puedan realizar ambas de forma equitativa.

Debido a la naturaleza poco predecible del problema, los experimentos no tratan con la misma modelización del problema para cada ejecución sino con una selección aleatoria de valores que intenta representar la realidad.

Esto es así ya que en una situación real no podemos prever los valores que estas pueden tomar y, en realidad, este trabajo cuenta con el objetivo de saber si tanto los algoritmos genéticos como el enfriamiento simulado son buenas técnicas para un problema de estas características, no para *un* problema en concreto. Si tuviéramos los parámetros siempre fijados, podríamos llegar a sacar conclusiones equivocadas sobre esto y llegar a pensar que, por resolver bien *un problema*, el algoritmo genético o enfriamiento simulado es bueno para resolver *este tipo de problemas*.

Por todo esto, se ha decidido que los parámetros del modelo del problema sean escogidos de forma parcialmente aleatoria en el momento de realizar el experimento. En la Tabla 1 podemos observar los valores que pueden tomar para cada tramo en los generadores y los dedicados a la población.

Nombre de la variable	Valor mínimo	Valor máximo
Generadores		
Porcentaje inicial de generación	0	1
Energías renovables		
Coste por kilovatio	0.1	0.5
Máxima generación (kW)	25	50
Coste operativo	10	30
Energías fósiles		
Coste por kilovatio	0.5	1
Máxima generación (kW)	50	75
Coste operativo	2.5	5

Población

<i>Proporción de energías renovables</i>	0.3	0.5
<i>Número de generadores</i>	10	20
<i>Número de tramos</i>	3	4
<i>Número de tramos de descanso</i>	1	2
<i>Demanda por tramo</i>	500	700

Tabla 1 - Rangos del modelo del problema

Gracias a este enfoque podemos encontrar un análisis seguramente menos sesgado sobre la utilidad de los diferentes algoritmos para la idiosincrasia del problema presentado.

3. ALGORITMO GENÉTICO

Los algoritmos genéticos (AG) son una familia de métodos de búsqueda y optimización inspirados en los principios de la evolución natural y la genética. Aprovechan mecanismos como la selección natural, la reproducción y la mutación para explorar soluciones eficientes a problemas complejos. Este enfoque se ha revelado como una herramienta poderosa en campos diversos, dada su capacidad para encontrar soluciones óptimas o casi óptimas en espacios de búsqueda vastos y complicados.

En el contexto del problema que nos ocupa, el cual implica el balance óptimo de cargas entre múltiples generadores y un único consumidor en una red eléctrica, los AG se presentan como una estrategia prometedora. Su naturaleza exploratoria y su capacidad para manejar múltiples variables y restricciones los hacen adecuados para abordar la complejidad inherente a este escenario.

El problema, como se describió previamente, plantea desafíos significativos debido a la variedad de variables involucradas y a la necesidad de balancear diferentes objetivos, como minimizar los costos desperdiciados y maximizar el uso de energías renovables. Los algoritmos genéticos, con su habilidad para navegar por espacios de soluciones complejas y encontrar compromisos entre objetivos conflictivos, se perfilan como una herramienta valiosa para abordar estas cuestiones.

En la siguiente sección, profundizaremos en cómo se pueden aplicar los algoritmos genéticos para resolver este problema de optimización. Exploraremos cómo se puede codificar la solución, qué operadores genéticos se pueden utilizar, y cómo se pueden ajustar los parámetros del algoritmo para adaptarse a las particularidades de nuestro escenario. Asimismo, discutiremos las ventajas y desafíos de emplear esta técnica en el contexto específico de la optimización de redes eléctricas, proporcionando así una visión integral de su aplicabilidad y eficacia.

3.1. CODIFICACIÓN

Debido a la naturaleza de nuestro problema, todo individuo solo se diferencia en esencia en un único parámetro: el porcentaje de generación de cada tramo para cada generador.

La forma más directa de codificar estos datos es en una matriz de dimensiones *número de generadores* \times *número de tramos* donde cada valor (i, j) de la matriz indica el porcentaje generado del generador i -ésimo en el tramo número j . El resto de las variables son en realidad parte del modelado del problema ya que son invariantes durante todo el algoritmo formando únicamente como ayuda en el resto de los cálculos y, por tanto, constantes para todos los individuos de la población.

3.1.1. REPARACIÓN

Debido a una de las restricciones de nuestro problema, los generadores no pueden tener todos los tramos de generación con porcentajes de generación mayores que cero. Como mínimo deben de tener igual a cero tantos porcentajes como se indique en las variables de tramos de descanso.

Por esto, se ha creado un proceso de reparación de los individuos. Se ha escogido esto frente a otras soluciones debido a la posible carga genética útil que este individuo puede aportar a la población. Haber escogido otra solución como la eliminación podría haber reducido la variabilidad genética de nuestra población y seguramente se perderían buenas soluciones fruto de esta eliminación.

El proceso de reparación se basa simplemente en devolver a cero aleatoriamente tantos valores de la variable como sean necesarios para cumplir la restricción. Esta reparación ocurre siempre que hay una alteración en la carga genética, es decir, en las fases de cruce y mutación.

3.2. PASOS DEL ALGORITMO

Cómo cualquier algoritmo genético está compuesto por los pasos de selección, cruce, mutación y reemplazo. Y, en esta sección, se verán en detalle las decisiones tomadas para cada una de las diferentes fases.

3.2.1. SELECCIÓN

Para este problema se ha escogido una selección por ruleta debido a la naturaleza elitista, pero a la vez conservadora de material genético de esta. Este tipo de selección nos permite obtener, de nuestra población, con una alta probabilidad individuos de gran calidad y, simultáneamente, con menos probabilidad aquellos con, pero calidad pero que (muy probablemente) tengan material genético que, recombinado, puedan dar lugar a individuos de alta calidad.

Ahora bien, debido a la naturaleza multiobjetivo del problema, había que decidir cómo se procedía con la selección para obtener los mejores individuos, si por coste o por uso de renovables. Es por ello por lo que se optó por escoger la mitad de cada uno, para así, de alguna forma, intentar que luego al recombinar se obtuvieran individuos aún mejores en ambas características, no solo en una.

Durante la selección entonces se calculan dos listas de porcentajes (donde cada una tiene las probabilidades a partir de los resultados de las dos funciones objetivo) y, cuando se va a seleccionar a un individuo, aleatoriamente se mira una lista u otra. Con esto, aproximadamente la mitad deberían ser bueno en una función mientras que la otra mitad debería ser bueno en la otra.

3.2.2. CRUCE

En un primer momento se intentó optar por un cruce en dos puntos, donde se escogía el índice de un generador (de forma aleatoria) de dos individuos, y se realizaban dos cortes en el array de valores de ambos para luego crear así dos nuevos individuos a partir de juntar la recombinación de estos cortes.

Esta técnica que podría parecer en primera instancia una buena idea para individuos bastante diferentes acababa por carecer de consistencia y la generación de nuevos individuos se acercaba demasiado a la simple aleatoriedad. Siendo así, se perdía el objetivo principal, el cual era que aquellas características positivas de un individuo se heredaran al siguiente y así sucesivamente.

Por esto, se cambió a un cruce por un punto, donde se cogían de igual forma un generador aleatorio de ambos individuos y se intercambiaban los porcentajes, pero ahora con un solo punto de corte en vez de dos. Esto en contraposición sí que consiguió una menor variabilidad y, como se verá posteriormente, esto consiguió heredar aparentemente ciertas características de un individuo a otro.

3.2.3. MUTACIÓN

Para la mutación se entendió que, al igual que en el cruce, una alta variabilidad podría no generar los resultados esperados. Es por ello por lo que se optó simplemente por que la mutación únicamente se hiciera sobre un valor de un tramo aleatorio de un generador aleatorio del individuo.

De esta forma, aunque el cambio es pequeño puede generar una gran diferencia en cuanto a los valores de las funciones objetivo debido a su naturaleza, aunque limitada, de exploración sobre nuevas soluciones. Una exploración más amplia podría dar lugar a demasiados valores inconsistentes con la restricción, con lo cual se deberían reparar los individuos y dar lugar a una variabilidad demasiado cercana a la pura aleatoriedad.

3.2.4. REEMPLAZO

En cuanto al reemplazo, se ha tenido en cuenta la idea de que generaciones anteriores pueden tener material genético interesante para las futuras generaciones. Es por ello por lo que, en el proceso de reemplazo, aunque se eliminan individuos con una cierta antigüedad (su generación está demasiado antigua respecto a la actual) esto se hace con un cierto umbral y se mantienen ciertas generaciones.

Por otro lado, una vez hecho esta primera criba se realiza la selección elitista sobre los individuos restantes. Esta selección elitista coje a la mitad de los mejores individuos en cada uno de los dos objetivos hasta sumar el número máximo de población, el cual es un parámetro del algoritmo.

Con este reemplazo conseguimos obtener un material genético diverso ya que nos encontramos con individuos buenos en ambos objetivos con la idea de, en el futuro cruce, intentar conseguir individuos que sean buenos en ambos objetivos o, al menos, mejores en uno de los dos. El enfoque además consigue ser lo suficientemente elitista para intentar perpetuar esas características que han llevado a ciertos individuos a ser mejores en una o ambas funciones objetivo.

3.3. CONDICIÓN DE PARADA

Para este problema se ha abordado la posibilidad de tener en cuenta la convergencia del algoritmo. En concreto se ha apostado por una parada basada en falta de mejora por parte de las funciones objetivo. En este modelaje lo que ocurre es que si después un cierto número de generaciones sin ningún tipo de mejora, el algoritmo se da por convergido y se para la ejecución.

En nuestro caso, este número de generaciones sin mejora no es estático sino dinámico y viene dado por el número de individuos de la población. Este valor se multiplica por un factor de diez y ahí tenemos la cantidad de generaciones sin mejora que el sistema admitirá. Si cualquiera de las dos funciones objetivo mejora en ese tiempo, se reinicia el contador y continua la evolución de nuestra población.

Gracias a este diseño encontramos un equilibrio entre el número de generaciones que necesitamos para encontrar cierto nivel de mejora. El algoritmo no se ejecuta por más tiempo del que no cree necesario para encontrar cierto nivel de mejora que, con muy mala suerte, a lo mejor ni llega.

3.4. PARÁMETROS

Para la ejecución del problema se han seleccionado unos parámetros del problema. Dependiendo de estos parámetros se pueden conseguir diferentes resultados, así como variar entre una resolución más enfocada a la explotación o a la exploración. A continuación, se van a definir que quiere indicar cada parámetro, así como algunos valores probados en los experimentos:

- **Factor de selección:** porcentaje de seleccionados que escogeremos frente a la población total. En nuestro problema hemos escogido un valor de 1.
- **Factor de cruce:** porcentaje de individuos que serán cruzados respecto a aquellos seleccionados. Se ha escogido un valor de 0.5.
- **Número máximo de individuos:** valor fijo que indica el número máximo de individuos que deben quedar después del reemplazo. En nuestro problema hemos utilizado un valor de 1000.
- **Antigüedad generacional:** número de generaciones que pueden vivir simultáneamente, como mucho se han conservado hasta 5 generaciones atrás.
- **Probabilidad de mutación:** número entre cero y uno que indica la probabilidad de que un individuo tenga una mutación, en nuestro caso era de 0.05.

Ajustando de una forma u otra estos parámetros conseguimos ejecuciones de múltiple tipo. Si por ejemplo aumentamos demasiado la probabilidad de mutación, el algoritmo tarda mucho más tiempo en converger en un óptimo debido a la alta variabilidad del material genético entre individuos, los cuales no consiguen evolucionar hasta encontrar una mejor solución. Otro caso podría ser el de bajar demasiado el número máximo de individuos, esto da lugar a una menor variabilidad y se acaba por conseguir un peor resultado medio debido a que nos estancamos demasiado rápidamente en un óptimo local de donde no se consigue salir.

4. ENFRIAMIENTO SIMULADO

El enfriamiento simulado (*Simulated Annealing*) es una técnica de optimización inspirada en el proceso físico de recocido de los metales, donde un material se calienta hasta alcanzar un estado de alta energía para luego ser enfriado lentamente, permitiendo que las partículas se reorganicen en una configuración de menor energía y, por ende, más estable. De manera análoga, el enfriamiento simulado busca encontrar la solución óptima de un problema de optimización navegando a través del espacio de soluciones y permitiendo, de manera controlada, la aceptación de soluciones peores con el objetivo de escapar de óptimos locales y aumentar las posibilidades de encontrar el óptimo global.

En este contexto, se considera un estado como una solución específica al problema y la energía como el valor de la función objetivo que se desea minimizar o maximizar. El algoritmo comienza con una solución inicial y una temperatura elevada, y en cada iteración se genera una nueva solución vecina. Si esta nueva solución es mejor, se acepta automáticamente; si es peor, la probabilidad de aceptación dependerá de cuánto peor sea y de la temperatura actual del sistema. A medida que el algoritmo avanza, la temperatura se reduce gradualmente, disminuyendo la probabilidad de aceptar soluciones peores y enfocando la búsqueda en la exploración del espacio local alrededor de las mejores soluciones encontradas.

El enfriamiento simulado ha demostrado ser eficaz para resolver una amplia variedad de problemas de optimización, especialmente aquellos con espacios de soluciones complejos y numerosos óptimos locales. Sin embargo, la eficacia del algoritmo depende en gran medida de la configuración de sus parámetros, incluyendo el esquema de enfriamiento, la generación de soluciones vecinas y la condición de parada. En las siguientes secciones, se explorarán en detalle estos aspectos y cómo se pueden ajustar para abordar de manera efectiva el problema de optimización del despacho de generación eléctrica.

En la sección que sigue, exploraremos con detenimiento cómo se puede aplicar la técnica de enfriamiento simulado para abordar el problema de optimización de generación eléctrica. Analizaremos detalladamente el proceso de configuración del algoritmo, incluyendo la selección de la solución inicial, la definición de la función de vecindad, el esquema de enfriamiento y los criterios de parada. Además, discutiremos las estrategias para superar los retos específicos de este problema, tales como la presencia de múltiples mínimos locales y la necesidad de equilibrar la exploración y la explotación del espacio de soluciones.

4.1. CODIFICACIÓN

Gracias a las similitudes en funcionamiento de este algoritmo, así como el diseño de la codificación que realizamos para el algoritmo genético, se ha podido aprovechar en su totalidad la forma de crear y utilizar el modelo de este. Por ello, no se ha necesitado realizar ningún cambio respecto a lo comentado en la sección 3.1 de este trabajo donde se comentaba la representación basada en la matriz de valores donde por cada generador encontramos sus porcentajes de generación para cada tramo horario.

4.2. PASOS

Este algoritmo se define en esencia por dos elementos que lo componen: la elección de la solución inicial, así como la forma escoger los vecinos para tener en cuenta en la elección del próximo candidato. En esta sección se verán las decisiones tomadas entorno a eso.

4.2.1. SOLUCIÓN INICIAL

Desde un principio y para poner sobre el mismo plano de dificultad para realizar un análisis competente sobre su eficacia para resolver este problema. Es por ello por lo que se ha optado por la misma decisión

que la tomada en el Algoritmo genético y se ha generado de igual forma se ha generado de forma aleatoria.

Otras alternativas como la utilización de una solución del algoritmo genético como solución inicial podrían haber corrompido la comparación dopando al enfriamiento simulado de un mejor resultado que él no ha generado en primera instancia. Si se hubiera diseñado de esa forma no tendríamos una comparación justa y podríamos llegar a sacar conclusiones erróneas sobre un posible proceso de mejora o no mejora de la solución.

4.2.2. ELECCIÓN DE VECINOS

En un primer lugar se optó por la utilización de diversas heurísticas que podrían generar un buen resultado pero que en la práctica no dieron los resultados esperados. Se acabó por concluir que, en realidad, volvían al algoritmo prácticamente aleatorio en vez de encontrar patrones de mejora, lo cual era el objetivo.

Una idea inicial fue la utilización de inversas de la probabilidad en los valores iniciales de generación. De esta forma, si un generador en un tramo generaba el 0.3 de su generación máxima, ahora pasaría a generar $1 - 0.3 = 0.7$. Esto tenía problemas ya que acotaba demasiado el espacio de soluciones, el cual para números reales es verdaderamente amplio.

Otra idea fue la de apagar o encender ciertos generados en un tramo determinado. De manera que, si un generador generaba cualquier valor en un tramo concreto, este ahora pasaría a no generar nada, y si no lo hacía ahora pasaría a hacerlo con un valor aleatorio. Cuando se probó resultó en una dinámica demasiado cambiante y que acababa por generar soluciones demasiado dispares entre sí y que no alcanzaban a mejorar el resultado inicial.

Por último, se decidió a probar el método de mutación empleado en el algoritmo genético, el visto en la sección 3.2.3. Esta técnica dio muy buen resultado, al encontrar un equilibrio entre la exploración de nuevas soluciones dispares y la explotación de ciertos conjuntos de valores que conseguían ser dominantes ante otros. De forma que, cada vez que se busca encontrar un vecino, en realidad estamos generando una solución igual la cual ha sido mutada.

4.3. CONDICIÓN DE PARADA

Por definición, en enfriamiento simulado contamos con un valor de temperatura que, a cada iteración, se va actualizando para permitirnos aceptar soluciones menos dominantes a las que tenemos y que, a lo mejor, nos consiguen hacer salir de óptimos globales.

En el caso de este trabajo, la función de enfriamiento se basaba simplemente en la multiplicación de la temperatura actual por un índice de enfriamiento. Cuando nuestra temperatura llegaba a un umbral definido, nos dábamos cuenta de que ya no valía la pena seguir buscando en el árbol de soluciones, ya que nos encontrábamos ya con una tolerancia demasiado baja a una no-dominancia de las soluciones.

4.4. PARÁMETROS

En la ejecución del problema se han escogido una serie de parámetros iniciales que han conseguido un buen equilibrio entre explotación y exploración para el problema dado. Se han definido los siguientes:

- **Temperatura inicial:** se ha escogido un valor de 1000.
- **Ratio de enfriamiento:** valor por el cual es multiplicada la temperatura a cada iteración. En nuestro caso era un factor de 0.9995.

- **Umbral de parada:** se ha escogido un valor de $1e-4$ para el valor de temperatura mínimo que se podría aceptar.

La elección de una temperatura inicial relativamente alta se realiza para fomentar la exploración en las etapas iniciales del algoritmo, permitiendo la aceptación de soluciones subóptimas con el fin de evitar quedarse atrapado en mínimos locales. Este valor alto proporciona al algoritmo la flexibilidad necesaria para explorar ampliamente el espacio de soluciones, incrementando las posibilidades de identificar regiones prometedoras del espacio de búsqueda.

Por otro lado, la ratio de enfriamiento determina cuán rápido disminuye la temperatura a lo largo de las iteraciones. Un valor de 0.9995 implica una disminución muy gradual, lo que asegura que el algoritmo no se vuelva demasiado conservador demasiado rápido. Esto ayuda a mantener un buen equilibrio entre exploración y explotación a medida que el algoritmo progresa. Sin embargo, una ratio de enfriamiento demasiado lento podría resultar en una convergencia más lenta, mientras que una ratio demasiado rápido podría llevar al algoritmo a volverse demasiado conservador prematuramente, perdiendo la capacidad de escapar de mínimos locales.

Es crucial destacar que la elección de estos valores específicos se ha basado en la experimentación y ajuste fino, ya que las características particulares del problema en cuestión pueden requerir ajustes para optimizar el rendimiento del algoritmo. En este sentido, realizar pruebas con diferentes configuraciones de parámetros y analizar su impacto en el rendimiento del algoritmo ha sido crucial para proporcionar una visión valiosa y ayudar a identificar la configuración óptima para el problema específico.

5. IMPLEMENTACIÓN

Para la implementación se ha realizado la división entre modelo y experimentación. De esta forma se ha podido reaprovechar gran parte del código en los dos algoritmos. De la misma forma, la estructura de la experimentación es igual para ambos, haciendo una runner encargada de recoger los datos que el visualizador luego mostrará para un mayor análisis de lo sucedido.

La utilización de Python como lenguaje de programación ha conseguido una fácil implementación, así como multitud de pruebas sobre el código de forma rápida y eficaz. Además, la utilización de sus estructuras como las clases ha conseguido los objetivos comentados anteriormente.

5.1. MODELO

5.1.1. CLASE GENERADOR

La clase generador se encarga de guardar los parámetros propios de cada generador. Aquí se incluyen tanto aquello común a todos los individuos (comentado en la sección 2.1) como aquello que cambia con cada individuo (el porcentaje de generación de sus tramos).

Además, la clase generador tiene las funciones necesarias para realizar la reparación, las mutaciones y el cruce entre generadores. Junto a lo anterior conforma una estructura de datos y utilidades muy reutilizable y que dota de mayor comprensión a la implementación.

5.1.2. CLASE INDIVIDUO

El individuo se compone por los generadores que intentan suplir al consumidor, así como las demandas de este para cada tramo horario. Además, tenemos aquí el cálculo de las funciones objetivo, el cual se devuelve en una tupla donde cada elemento es el resultado de una de estas (primero el coste, luego la generación efectiva renovable). Por último, aquí tenemos la función de generación de vecinos, así como la de mutación.

5.1.3. CLASE POBLACIÓN

Esta clase se basa en un conjunto de individuos. Aquí es donde se concentran los parámetros de control y se ejecutan las funciones de selección y reemplazo a partir de la función de evolución. Para acabar, también encontramos aquí la función que calcula la frontera de Pareto sobre nuestra población.

5.2. EXPERIMENTACIÓN

5.2.1. CLASE RUNNER

En la clase runner se seleccionan los parámetros escogidos sobre el problema y se van guardando la información resultante de las iteraciones. Aquí podemos encontrar cosas como la condición de parada, así como estructuras para guardar los resultados de los mejores individuos de cada iteración.

5.2.2. CLASE VISUALIZADOR

El visualizador simplemente utiliza los datos recogidos de la clase runner para generar gráficas de tres tipos: una relación entre los resultados de las funciones objetivos frente al número e iteraciones, otra sobre la frontera de Pareto y, por último, una con la distribución de los valores de *fitness* sobre la población final.

6. EVALUACIÓN DE LOS RESULTADOS

La fase de evaluación es un componente crucial en el proceso de implementación de cualquier algoritmo de optimización, ya que proporciona una visión objetiva y cuantitativa de su rendimiento y eficacia. Esta sección está dedicada a analizar y valorar los resultados obtenidos a través de la implementación de ambos algoritmos, con el objetivo de entender en profundidad su comportamiento, identificar sus puntos fuertes y áreas de mejora, y comparar su desempeño con otras técnicas de optimización.

Para llevar a cabo una evaluación exhaustiva, se emplearán una serie de métricas y criterios de rendimiento específicos, que permitirán cuantificar la calidad de las soluciones encontradas, la eficiencia computacional y la capacidad del algoritmo para superar óptimos locales. Además, se realizarán análisis comparativos con los resultados, proporcionando así un marco de referencia para valorar la efectividad de ambos algoritmos en el contexto del problema específico abordado.

Es imperativo subrayar la importancia de utilizar conjuntos de datos y condiciones de prueba consistentes a lo largo de la evaluación, asegurando que los resultados sean comparables y la evaluación sea justa y objetiva. Asimismo, se pondrá especial énfasis en la interpretación de los resultados, buscando no solo identificar qué algoritmo tiene un rendimiento superior, sino también comprender por qué y en qué condiciones específicas.

Para cada algoritmo se analizarán tres experimentos representativos de los múltiples que se realizaron y se compararán entre sí para una comprensión más amplia de la idiosincrasia del problema.

6.1. ALGORITMO GENÉTICO

En la Ilustración 2 podemos observar los resultados del primer experimento en dos gráficos. El primero nos muestra el número de generación vs el costo/generación renovable: en el eje X, tenemos la "Generación" que representa el número de iteraciones o generaciones del algoritmo genético. En el eje Y, vemos dos métricas donde la línea del costo muestra una tendencia descendente inicial y luego se estabiliza en un valor cercano a 750. La línea de generación renovable, por otro lado, tiene una tendencia ascendente pronunciada al principio y luego se estabiliza alrededor de 700.

En segundo lugar, tenemos la frontera de Pareto de costo vs generación renovable. En este gráfico, el eje X representa el "Costo" y el eje Y la "Generación Renovable". La curva ilustra el *trade-off* entre ambas métricas. Observamos que al principio hay un rápido aumento en la generación renovable con un aumento marginal en el costo. Sin embargo, después de cierto punto, para aumentar más la generación renovable, el costo también aumenta de forma más significativa.




Ilustración 2 - Resultados del experimento 1 de algoritmo genético

Podemos entonces observar que en la imagen anterior el algoritmo genético converge rápidamente hacia soluciones óptimas, evidenciado por la estabilización de las métricas de costo y generación renovable en

las primeras generaciones. La Frontera de Pareto ilustra el compromiso inherente entre minimizar el costo y maximizar la generación renovable. A medida que se intenta aumentar la generación renovable, el costo también sube, mostrando que obtener más energía renovable se vuelve progresivamente más costoso. Esta representación visual es crucial para los tomadores de decisiones al equilibrar la eficiencia económica con la producción de energía renovable.

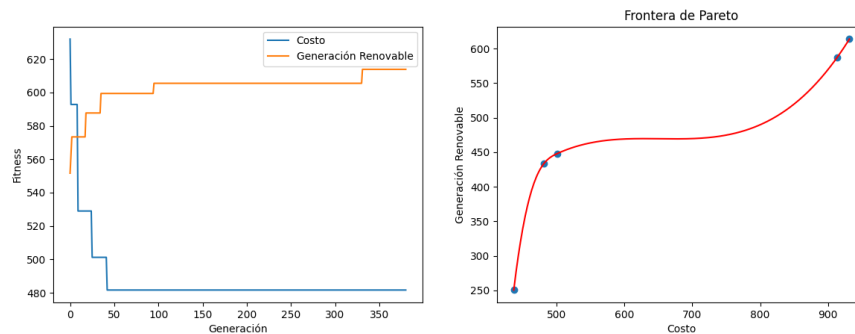


Ilustración 3 - Resultados del experimento 2 de algoritmo genético

Comparando la Ilustración 3 (que forma parte del segundo experimento) con la anterior, en esta nueva representación el algoritmo genético presenta una convergencia más gradual y demora más generaciones en estabilizarse. Se observa un incremento más pronunciado en la generación renovable, que alcanza valores superiores, aunque a un costo ligeramente mayor. La Frontera de Pareto revela una pendiente más acentuada, indicando que se requiere un mayor costo para lograr incrementos sustanciales en la generación renovable. Esto sugiere que, aunque esta solución proporciona más energía renovable, el coste asociado es más elevado en comparación con el experimento anterior.

Por último, si observamos la Ilustración 4, es evidente que el algoritmo genético se ha estancado en un óptimo local en este tercer experimento. Esto lo demuestra el hecho de que la generación renovable no aumenta significativamente a pesar de las numerosas generaciones transcurridas, y el costo se mantiene relativamente constante. Esta situación se refleja también en las distribuciones: hay un pico prominente en una región específica de costos y generación renovable, lo que indica que muchas soluciones están agrupadas en ese rango. La naturaleza aleatoria de los algoritmos genéticos puede ser tanto una fortaleza como una debilidad. Mientras que la aleatoriedad permite explorar un amplio espacio de soluciones y potencialmente encontrar óptimos globales, también puede llevar al algoritmo a estancarse en óptimos locales.

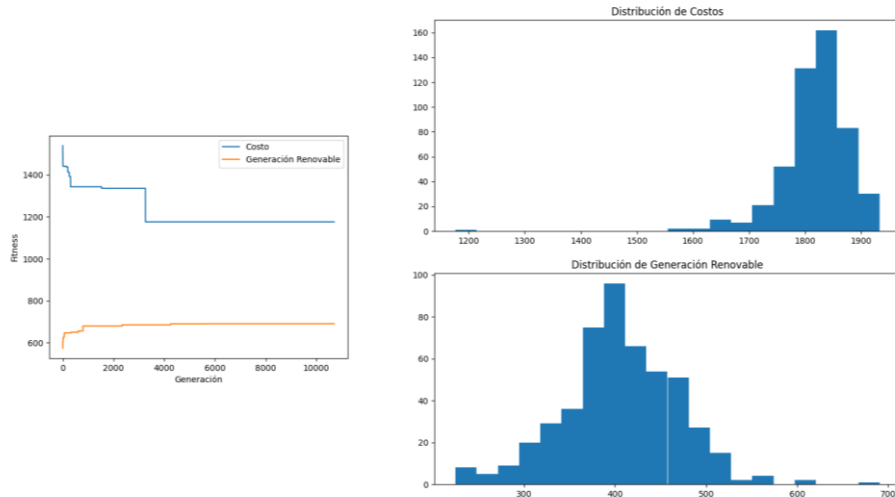


Ilustración 4 - Resultados del experimento 3 de algoritmo genético

Para abordar este desafío, se podrían adoptar estrategias como la reintroducción de diversidad en la población, mediante operadores de mutación más agresivos o técnicas de elitismo modificadas. Además, realizar múltiples ejecuciones del algoritmo y combinar sus resultados puede ayudar a contrarrestar el efecto del estancamiento y aprovechar al máximo la naturaleza aleatoria del algoritmo para obtener una solución óptima.

6.2. ENFRIAMIENTO SIMULADO

Los resultados del primer experimento de enfriamiento simulado que podemos ver en la Ilustración 5 muestran un descenso notable y rápido en el costo al inicio, estabilizándose cerca de las 10,000 iteraciones. Posteriormente, el costo permanece prácticamente constante. Por otro lado, la generación renovable aumenta ligeramente y luego se estabiliza, manteniéndose constante por un largo período de iteraciones. Al observar la Frontera de Pareto, vemos de nuevo un comportamiento de *trade-off* entre el costo y la generación renovable, y se observa una estabilización cercana al extremo derecho.

Comparando con el algoritmo genético, mientras que el algoritmo genético requería varias generaciones para conseguir mejoras incrementales, el enfriamiento simulado parece haber encontrado rápidamente una solución cercana al óptimo y luego se estabilizó. Esto sugiere que el enfriamiento simulado fue más eficiente en términos de rapidez para alcanzar un resultado óptimo en este caso. Sin embargo, es importante considerar que la naturaleza de los algoritmos es diferente: mientras que el genético trabaja con una población de soluciones y las combina, el enfriamiento simulado explora el espacio de soluciones de forma más dirigida, aceptando soluciones peores con una probabilidad decreciente a medida que avanza el tiempo.

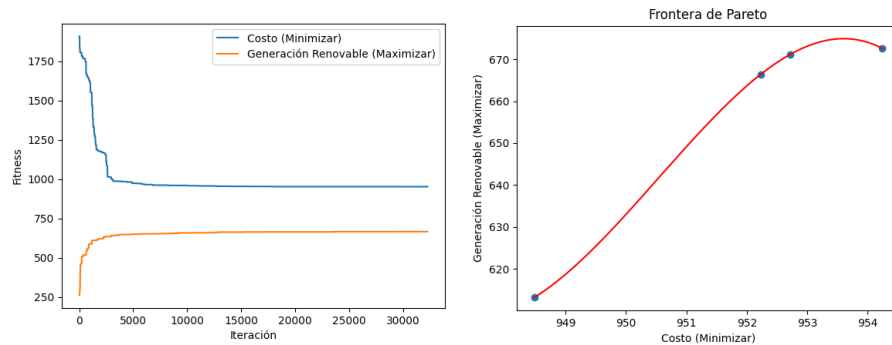


Ilustración 5 - Resultados del experimento 1 de enfriamiento simulado

En el segundo experimento de enfriamiento simulado, como podemos observar en la Ilustración 6, se ve un comportamiento similar en la gráfica de iteraciones: el costo disminuye rápidamente al comienzo y luego se estabiliza, mientras que la generación renovable muestra un aumento inicial y luego se nivela. Sin embargo, hay algunas diferencias notables. El costo en el segundo experimento inicia con valores más altos, pero se estabiliza en un rango similar al del primer experimento. La generación renovable, por otro lado, alcanza valores más altos en el segundo experimento en comparación con el primero.

La Frontera de Pareto del segundo experimento presenta una característica distintiva: a diferencia del primer experimento donde la frontera era más suave y continua, aquí observamos picos y valles, lo que indica soluciones de compromiso más variadas entre costo y generación renovable. Es evidente que hubo más fluctuaciones en las soluciones encontradas en el espacio de búsqueda.

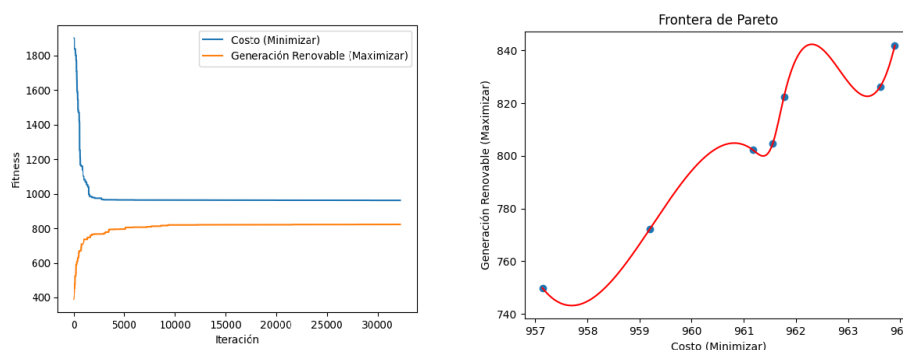


Ilustración 6 - Resultados del experimento 2 de enfriamiento simulado

Comparando los dos experimentos de enfriamiento simulado, el segundo parece haber explorado un espacio de soluciones más diverso, lo que le permitió alcanzar valores más altos de generación renovable. Esto podría indicar que el segundo experimento tenía una configuración o parámetros diferentes que le permitieron escapar de óptimos locales y explorar más a fondo el espacio de soluciones. Es esencial considerar estos parámetros al configurar algoritmos como el enfriamiento simulado para optimizar su eficacia.

Por último, en la Ilustración 7 podemos observar el tercer experimento, el cual muestra características distintivas en comparación con los dos anteriores. Al observar la gráfica de iteraciones, vemos que el costo disminuye de manera abrupta en las primeras iteraciones y luego se estabiliza tempranamente, alcanzando niveles más bajos en comparación con los otros experimentos. La generación renovable, por su parte, experimenta un alza inicial para luego nivelarse, pero su estabilización ocurre en valores más elevados que en los experimentos previos.

Las distribuciones de costos y generación renovable revelan otra diferencia notable: en ambos casos, las soluciones están altamente concentradas en rangos específicos, lo que indica que el algoritmo encontró un conjunto de soluciones óptimas y se enfocó en ellas. Esta alta concentración podría señalar que el algoritmo ha convergido rápidamente hacia una solución óptima sin quedarse atrapado en óptimos locales.

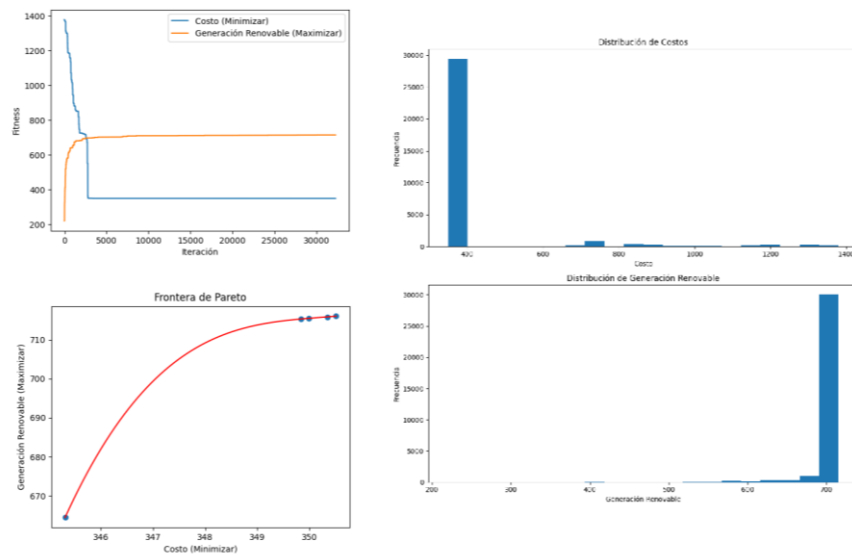


Ilustración 7 - Resultados del experimento 3 de enfriamiento simulado

7. CONCLUSIONES

El presente trabajo ha abordado la resolución de un problema de optimización complejo, empleando para ello dos algoritmos distintos: el Algoritmo Genético y el Enfriamiento Simulado. A través de la implementación detallada y el análisis exhaustivo de los resultados obtenidos, hemos podido extraer diversas conclusiones sobre el comportamiento, eficacia y áreas de mejora de ambos métodos.

El Algoritmo Genético ha demostrado ser capaz de encontrar soluciones óptimas de manera eficiente, convergiendo rápidamente hacia soluciones cercanas al óptimo en los diferentes experimentos realizados. Sin embargo, se ha observado que este método puede quedar susceptible al estancamiento en óptimos locales, como se evidenció en el tercer experimento. A pesar de este desafío, la naturaleza poblacional y los operadores genéticos del algoritmo han facilitado la exploración del espacio de soluciones, mostrando un buen equilibrio entre la explotación y exploración.

Por su parte, el Enfriamiento Simulado ha destacado por su capacidad para encontrar rápidamente soluciones cercanas al óptimo, adaptándose de manera eficiente a la topología del espacio de soluciones. Este método ha probado ser particularmente efectivo en evitar el estancamiento en óptimos locales, explorando el espacio de soluciones de manera más dirigida. Sin embargo, su eficacia depende en gran medida de la configuración de sus parámetros, lo cual se ha evidenciado en las diferencias observadas entre los distintos experimentos.

Al comparar ambos algoritmos, se hace evidente que, mientras el Algoritmo Genético proporciona una robusta capacidad para explorar y explotar el espacio de soluciones gracias a su enfoque poblacional, el Enfriamiento Simulado sobresale por su rapidez y eficiencia para alcanzar soluciones óptimas, evitando quedar atrapado en soluciones subóptimas.

En el contexto específico del problema abordado, relacionado con la optimización de la generación de energía, ambos algoritmos han demostrado ser herramientas valiosas. Sin embargo, la elección entre uno u otro dependerá de las características particulares del problema, así como de los objetivos y restricciones específicas del caso de estudio.

7.1. IMPLICACIONES Y FUTURAS LÍNEAS DE INVESTIGACIÓN

Los resultados obtenidos en este trabajo no solo aportan luz sobre la idoneidad de los algoritmos para el problema específico de optimización energética, sino que también abren la puerta a futuras líneas de investigación. Sería interesante explorar la combinación de ambos métodos, buscando sinergias que potencien sus fortalezas y mitiguen sus debilidades. Asimismo, sería provechoso investigar el ajuste fino de los parámetros y la implementación de técnicas avanzadas para mejorar la diversidad y evitar el estancamiento en óptimos locales.

En conclusión, este trabajo ha proporcionado un análisis riguroso y detallado de dos métodos de optimización prominentes, demostrando su aplicabilidad y eficacia en el ámbito de la generación de energía. Los *insights* obtenidos no solo son valiosos para el problema específico abordado, sino que también contribuyen al cuerpo general de conocimiento en el campo de la optimización y la inteligencia computacional.